

# Dokumentacja do

## WSI - ćwiczenie 2

### Algorytmy ewolucyjne i genetyczne

Wykonano przez Marfenko Mykhailo

**Struktura programu** Program jest podzielony na 2 pliki:

**genetic\_algorithm.py** – Ten plik zawiera główną funkcję `genetic_algorithm()` która jest wywołana z `main`.

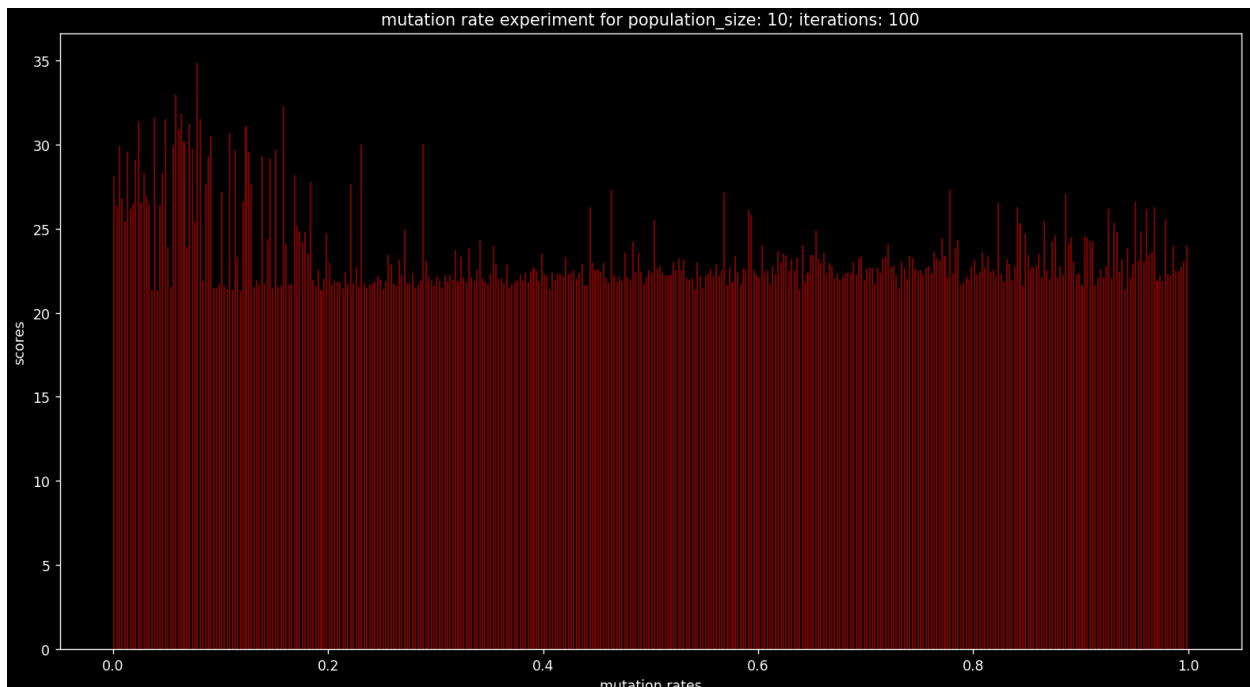
**experiments.py** – tutaj znajdują się 3 funkcje: `mutation_rate_experiment()`; `population_size_experiment()` oraz `iterations_experiment()` które badają wpływ odpowiedniego hiperparametru: `mutation_rate`; `population_size`; `iterations`.

Rozpatrzmy działanie algorytmu dla `iterations = 500`; `population_size = 500`; `mutation_rate = 0.25`:

\*wszystkie eksperymenty będą mieli punkt początkowy rodziców w przydziale od (-1;-1) do (1; 1)

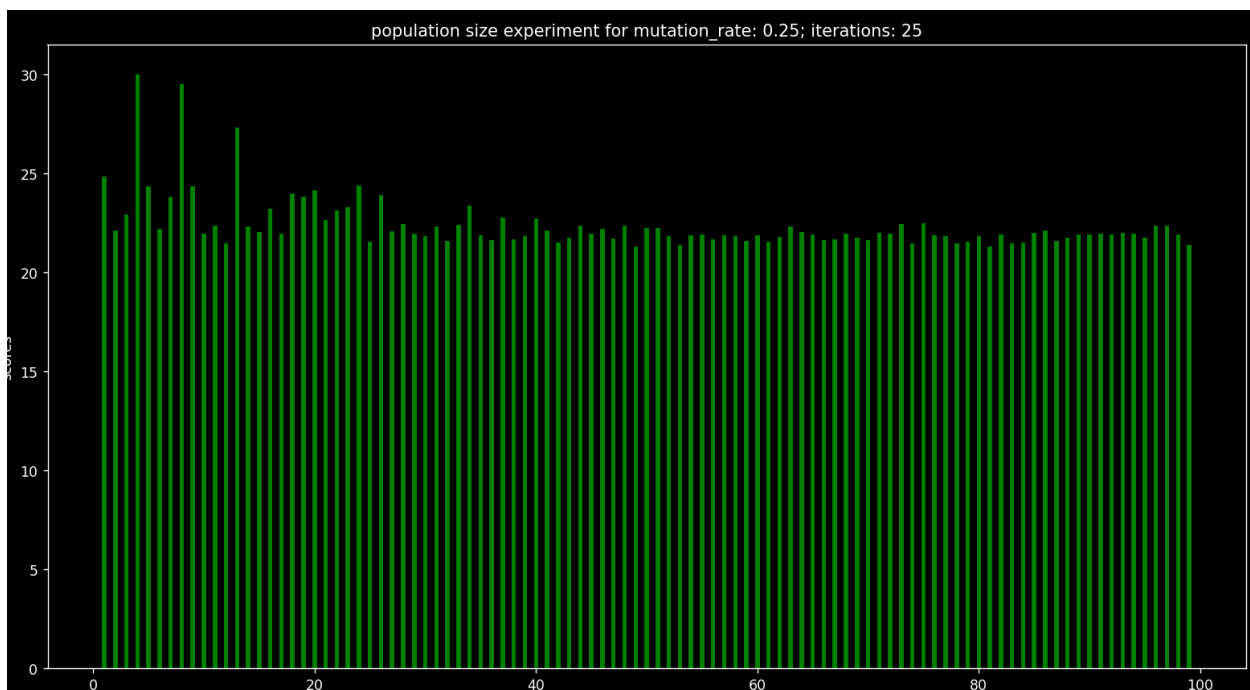
```
Iteration: 0   with new best score: 27.018439863011913   with coords: (0.9912867130824008, 0.6722914799301964)
Iteration: 0   with new best score: 26.88783024284716   with coords: (0.7510658077921726, 0.9021920194230075)
Iteration: 0   with new best score: 25.783096536913416   with coords: (0.9030013205213687, 0.8411209290536155)
Iteration: 0   with new best score: 24.371513660053004   with coords: (0.8773150803993859, 0.9479169759928034)
Iteration: 1   with new best score: 23.49606749786951    with coords: (1.0368849764054398, 0.9284379723397213)
Iteration: 1   with new best score: 23.011490212496703   with coords: (1.074331976038326, 0.9975648593360181)
Iteration: 3   with new best score: 22.479060199922124   with coords: (1.0384813809729594, 1.0140508577842187)
Iteration: 9   with new best score: 21.956316847163922   with coords: (0.9913590268405337, 0.9739187933301197)
Iteration: 10  with new best score: 21.925431195486812   with coords: (0.9904166739667982, 1.020603733728776)
Iteration: 11  with new best score: 21.81394162414876    with coords: (0.9855578595636616, 1.0119214687214053)
Iteration: 19  with new best score: 21.71723950339098    with coords: (0.9906975112297598, 0.9864101465615257)
Iteration: 20  with new best score: 21.3292407269414    with coords: (0.9967176132357436, 0.9998674740690914)
Iteration: 126 with new best score: 21.321837682002382   with coords: (1.0000078478879195, 0.9972314272289753)
Iteration: 148 with new best score: 21.30125724338008    with coords: (0.9996858418696264, 0.9985056125170472)
Iteration: 350 with new best score: 21.28268479163135    with coords: (0.99974675123701, 0.9993472126426927)
Best score is: 21.28268479163135 with coordinates: (0.99974675123701, 0.9993472126426927)
21.26435864903798
```

Teraz zbadamy wpływ `mutation_rate` która przyjmuje wartości od 0.001 do 1 z krokiem w 0.0025:



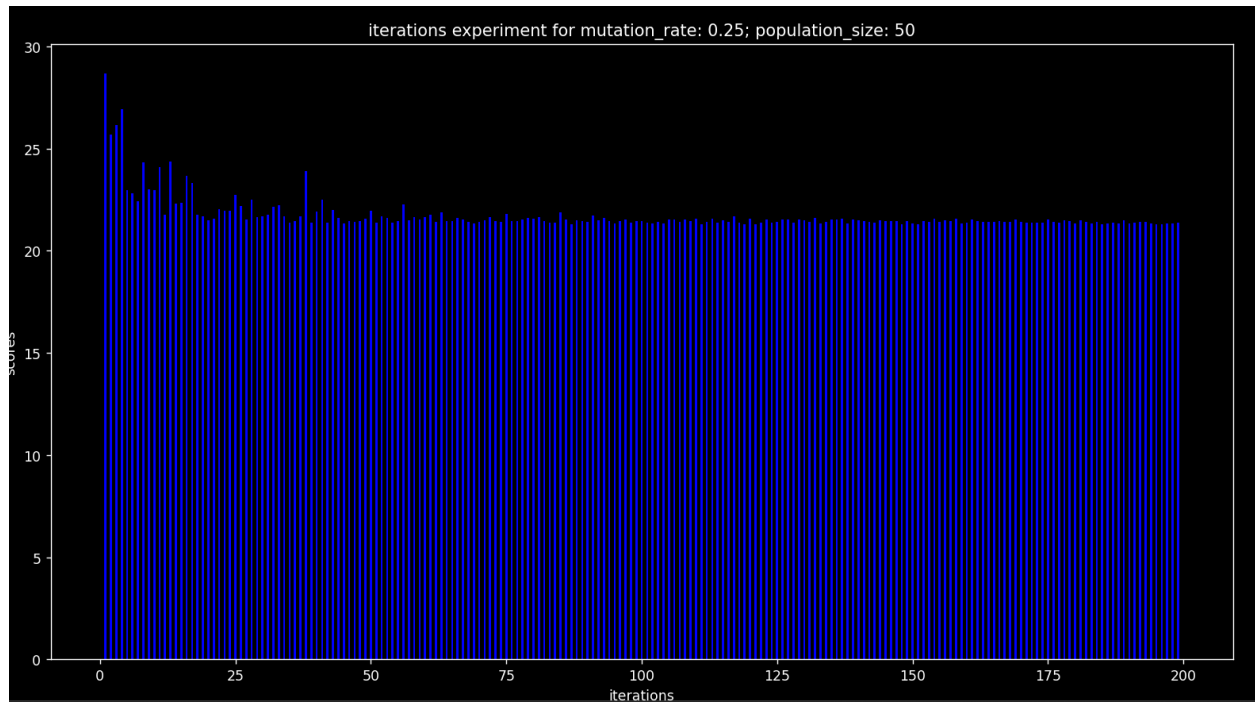
**Komentarz:** mutation\_rate nie ma wielkiego wpływu. Można zauważyć że im większy mutation rate, tym mniej poprawny wynik średnio. Jest tak ponieważ nawet jeżeli algorytm znajdzie bardzo dobry wynik, to po mutacji on bardzo zmieni się. Też jest ważne żeby nie wybrać za małą liczbę ponieważ wtedy algorytm może nie zdążyć wystarczająco zmodyfikować dzieci jeżeli będzie za mało iteracji, ale to raczej nie wielki problem kiedy rodzice mają losowy punkt początkowy.

Teraz zbadamy wpływ population\_size która przyjmuje wartości od 1 do 100 z krokiem w 1:



**Komentarz:** Nie wątpliwie im większa populacja początkowa, tym lepiej będą wyniki. Ale nawet przy małej populacji czasem można otrzymać dobry wynik, ale to już bardziej kwestia losowości.

Teraz zbadamy zależność parametru iterations która przyjmuje wartości od 1 do 200 z krokiem w 1



**Komentarz:** Nie wątpliwie im większa liczba iteracji, tym lepiej będą wyniki...